# 清华大学电子工程系 **媒体与认知** 课堂 2

#### 2023-2024 学年春季学期

#### 作业2

元敬哲 2022010657

2024年5月5日

# 理论部分

- 1 单选题 (15 分)
- 1.1 C
- 1.2 D
- 1.3 B
- 1.4 C
- 1.5 B
- 2 计算题 (15 分)
- 2.1 已知某卷积层的输入为 X(该批量中样本数目为 1, 输入样本通道数为 1), 采用一个卷积核 W, 即卷积输出通道数为 1, 卷积核尺寸为 2×2, 卷积的步长为 1, 无边界延拓, 偏置量为 b:

$$X = \begin{bmatrix} 0.5 & -0.2 & 0.3 \\ 0.6 & 0.4 & -0.1 \\ -0.4 & 0.5 & 0.2 \end{bmatrix}, W = \begin{bmatrix} 0.1 & -0.2 \\ -0.3 & 0.4 \end{bmatrix}, b = 0.04$$

2.1.1 请计算卷积层的输出 Y。

解:

依题意, Y的大小为 $(2 \times 2)$ 。

$$Y_{11} = 0.5 \times 0.1 + (-0.2) \times (-0.2) + 0.6 \times (-0.3) + 0.4 \times 0.4 + b = 0.03$$

$$Y_{12} = -0.2 \times 0.1 + 0.3 \times (-0.2) + 0.4 \times (-0.3) + (-0.1) \times 0.4 + b = -0.20$$

$$Y_{21} = 0.6 \times 0.1 + 0.4 \times (-0.2) + (-0.4) \times (-0.3) + 0.5 \times 0.4 + b = 0.12$$
 
$$Y_{22} = 0.4 \times 0.1 + (-0.1) \times (-0.2) + 0.5 \times (-0.3) + 0.2 \times 0.4 + b = -0.01$$
 所以

$$Y = \begin{bmatrix} 0.03 & -0.20 \\ 0.12 & -0.01 \end{bmatrix}$$

2.1.2 若训练过程中的目标函数为 L,且已知  $\frac{\partial L}{\partial Y}=\begin{bmatrix} 0.3 & 0.1\\ -0.4 & 0.2 \end{bmatrix}$ ,请计算  $\frac{\partial L}{\partial X}$ 。

注:本题的计算方式不限,但需要提供计算过程以及各步骤的结果。

解:

由题,

$$\frac{\partial L}{\partial X} = \begin{bmatrix} W_4 & W_3 \\ W_2 & W_1 \end{bmatrix} * \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & \delta_{Y1} & \delta_{Y2} & 0 \\ 0 & \delta_{Y3} & \delta_{Y4} & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

所以

$$\delta_{X1} = 0.3 \times 0.1 = 0.03$$

$$\delta_{X2} = 0.3 \times (-0.2) + 0.1 \times 0.1 = -0.05$$

$$\delta_{X3} = 0.1 \times (-0.2) = -0.02$$

$$\delta_{X4} = 0.3 \times (-0.3) + (-0.4) \times 0.1 = -0.13$$

$$\delta_{X5} = 0.3 \times 0.4 + 0.1 \times (-0.3) + (-0.04) \times (-0.2) + 0.2 \times 0.1 = 0.19$$

$$\delta_{X6} = 0.1 \times 0.4 + 0.2 \times (-0.2) = 0$$

$$\delta_{X7} = -0.4 \times (-0.3) = 0.12$$

$$\delta_{X8} = -0.4 \times (0.4) + 0.2 \times (-0.3) = -0.22$$

$$\delta_{X9} = 0.2 \times 0.4 = 0.08$$

$$\frac{\partial L}{\partial X} = \begin{bmatrix} 0.03 & -0.05 & -0.02\\ -0.13 & 0.19 & 0\\ 0.12 & -0.22 & 0.08 \end{bmatrix}$$

# 编程部分

# 3 编程作业报告

# 3.1 探究 batch normalization 和 dropout 的作用

#### 3.1.1 使用默认配置

如图所示, 训练准确率最高为 0.906:



图 1: 默认配置的结果

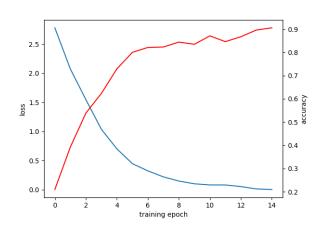


图 2: 默认配置训练可视化

#### 3.1.2 启用 BN

如图所示, 训练准确率最高为 0.965:



图 3: bn 的结果

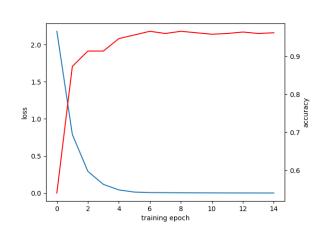


图 4: bn 训练可视化

#### 3.1.3 启用 dropout

如图所示, 训练准确率最高为 0.900:

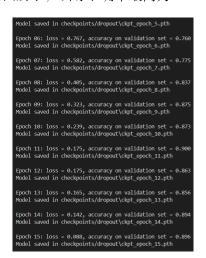


图 5: dropout 的结果

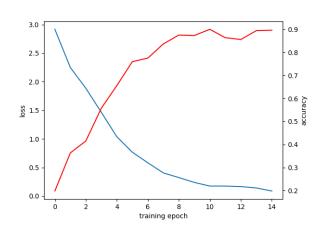


图 6: dropout 训练可视化

#### 3.1.4 测试集上测试

如图所示,默认测试如下:

25 <u>D:\清华文件\大二下\媒体与认知\hw2\hw2\nd2\code</u>> <mark>python test.py --ckpt\_path checkpoints/default --epoch **15** [Info] loading checkpoint from checkpoints/default\ckpt\_epoch\_15.pth ... accuracy on the test set: 0.904</mark>

图 7: 默认测试

准确度为: 0.904。

bn 测试如下:

PS D:\清华文件\大二下\媒体与认知\hw2\mu2\code> python test.py --ckpt\_path checkpoints/bn --epoch 9 [Info] loading checkpoint from checkpoints/bn\ckpt\_epoch\_9.pth ... accuracy on the test set: 0.951

图 8: bn 测试

准确度为: 0.951。

dropout 测试如下:

PS D: 清华文件(大二下)媒体与认知\Mz\code> python test.py --ckpt\_path checkpoints/dropout --epoch 11 [Info] loading checkpoint from checkpoints/dropout\ckpt\_epoch\_11.pth ... accuracy on the test set: 0.874 \_ \_ \_

图 9: dropout 测试

准确度为: 0.874。

在 bn 之后,Batch Normalization 层还有助于防止梯度爆炸和梯度消失。对每个特征的输入进行归一化,使其均值接近于 0,方差接近于 1,这样可以使输入数据分布更稳定,减少网络层之间的协变量偏移,有助于提高训练效果。此外,它还可以加速训练收敛,改善模型泛化能力,减少对参数初始化的敏感性,并允许使用较大的学习率,进一步加快训练速度,提高准确率。

Dropout 可以通过打破高权重连接的路径来缓解收敛缓慢问题,确保没有一条路径变得过于主导。因此,梯度可以更自由地流动并促进更快的收敛。但是本次实验 dropout 后的效果可能变差,可能是因为丢弃的神经元太多导致模型无法有效运行。

#### 3.2 探究数据增广的作用

在 datasets.py 中定义的数据增广变换所得的图片如下:

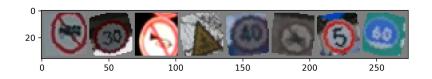


图 10: 数据增广变换后的图片

我所使用的数据增广变换为:改变色彩的亮度、对比度和饱和度。以及在 [-19.5°,19.5°] 间随机旋转。原因是这样的变换比较符合真实的各种情况的数据分布。并且小角度的随机旋转可以模拟不同拍摄角度带来的偏差,且不会改变标志语义。

训练及测试结果如下:

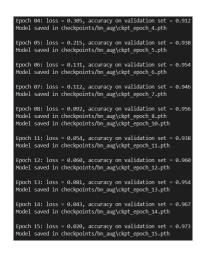


图 11: 增广后的结果

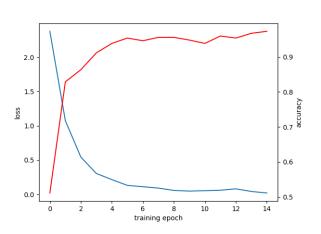


图 12: dropout 增广可视化

训练的准确率为 0.973。

PS D:\清华文件\大二下\媒体与认知\hw2\fw2\code> python test.py --ckpt\_path checkpoints/bn\_aug --epoch 15 [Info] loading checkpoint from checkpoints/bn\_aug\ckpt\_epoch\_15.pth ... accuracy on the test set: 0.971

图 13: 增广后测试结果

测试准确率为 0.971。

# 3.3 探究空间变换网络 (STN) 的作用

使用 stn 后, 训练及测试结果如下:

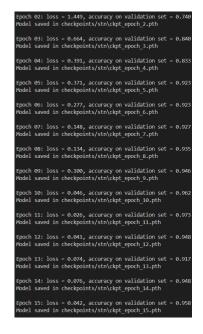


图 14: 用 stn 的结果

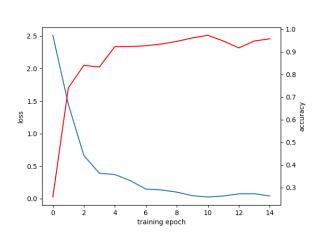


图 15: stn 可视化

训练准确率最高为 0.973, 高于不用 stn 的情况。

图 16: stn 测试结果

使用 stn 后测试准确率为 0.963。

### 3.4 可视化

#### 3.4.1 卷积核可视化

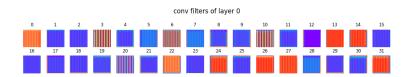


图 17: 第 0 层卷积层的卷积核

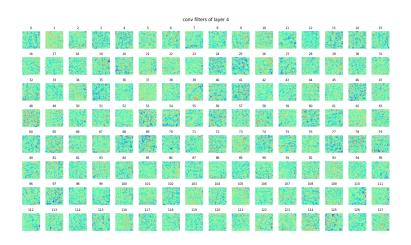


图 18: 第 4 层卷积层的卷积核

由图可见, 浅层卷积核颜色、方向简单, 深层的卷积核有更加复杂多 样的模式。

#### 3.4.2 卷积层的输出特征图

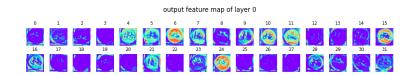


图 19: 第 50 张图像第 0 层卷积层的输出特征图

由图可知, 层数越大, 特征提取越抽象和细节。

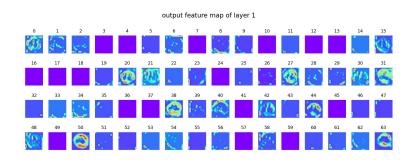


图 20: 第 50 张图像第 1 层卷积层的输出特征图

#### 3.4.3 t-SNE 可视化最后一层隐藏层的输出特征

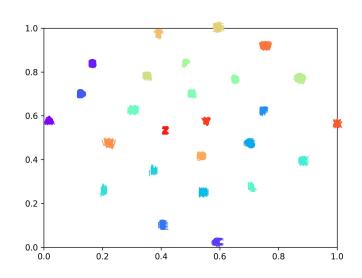


图 21: t-SNE 可视化最后一层隐藏层的输出特征图

将最后一层隐藏层的输出特征降维到 2 维并绘制,可见各个分类点比较分散,分类情况良好。

#### 3.4.4 可视化 STN 学习到的变换

# original transformed

The Effect of the Spatial Transformer Network

图 22: 可视化 STN 学习到的变换图

由图,可见 stn 对图片做了裁切放大和变换视角的操作。

# 3.5 总结与反思

本次实验遇在调试的时候遇到了代码中使用 inplace 操作导致的计算梯度消失的问题。经过不断 debug,发现是使用了 += 操作符,后来改为两个式子相加,out=out+x,才解决了这一问题。本次实验略微使用了大语言模型,在初始化全连接网络最后一个线性层的权重/偏置时使用 LLM,解决了自己写导致的维度不匹配的问题。